

# EcoMonitor

Alumnos:

- Ulises Jaramillo Portilla — A01798380
- Jesús Ángel Guzmán Ortega — A01799257
- Sebastian Espinoza Farías — A01750311
- Santiago Villazón Ponce de León — A01746396
- Luis Ubaldo Balderas Sanchez — A01751150
- José Antonio Moreno Tahuilán — A01747922

## 1. Introducción

EcoMonitor es un **sistema de monitoreo ambiental completo** que integra hardware, software, aplicaciones móviles y análisis con **inteligencia artificial**.

Su objetivo es recolectar datos ambientales (temperatura, humedad, luz, calidad del aire, etc.), almacenarlos y visualizarlos en tiempo real, además de aplicar **modelos predictivos y detección de anomalías**.

Este proyecto fue desarrollado como parte de la **Práctica 3 de Dispositivos embebidos con sensores e interfaces móviles** del módulo *Integración de HW para ciencia de datos*.

---

## 2. Arquitectura General

El sistema está compuesto por tres grandes bloques:

### 1. Hardware embebido (IoT)

- Arduino UNO con sensores:
  - DHT22 (temperatura y humedad).
  - LDR (intensidad lumínica).
  - Sensor MQ-135 (calidad del aire, en versiones extendidas).
- Almacenamiento en CSV vía módulo SD o transmisión por puerto serie.

### 2. Backend API (Flask)

- API REST ligera en Python.
- Ingesta de datos desde **Google Sheets** o CSV local.
- Endpoints:
  - `/` (info general).
  - `/data` (datos con filtros por sensor, dispositivo y fechas).
  - `/sensors` (lista de sensores).
  - `/devices` (lista de dispositivos).
- Compatible con despliegue en **Docker**.
- Gestión de errores (404, 500, validación de fechas).

### 3. Frontend móvil (Flutter)

- Aplicación multiplataforma (Android, iOS, Web).
- Interfaz responsiva tipo **dashboard ambiental**.
- Gráficas de series temporales y filtros por sensor/dispositivo.
- Conexión directa al Backend API.
- Soporta **hot reload** y builds de producción.

### 4. Machine Learning & Análisis Predictivo

- Procesamiento de datos con **pandas/numpy**.
- **Detección de anomalías** con *Isolation Forest*.
- Modelos de predicción:
  - Regresión Lineal.
  - Random Forest.

- LSTM (deep learning para series temporales, opcional si TensorFlow está disponible).
  - Predicciones de valores futuros (hasta 24 horas).
  - Visualizaciones:
    - Series temporales con anomalías.
    - Distribuciones.
    - Predicciones futuras.
    - Matrices de correlación.
- 

### 3. Objetivos de la práctica

- Diseñar un sistema embebido de **monitoreo ambiental** con Arduino y sensores.
  - Almacenar datos en **CSV** y transmitirlos vía puerto serie.
  - Construir un **Backend API** que sirva como capa de acceso a los datos.
  - Desarrollar un **Frontend móvil multiplataforma** para visualización de la información.
  - Implementar un **modelo de Machine Learning** que permita:
    - Detectar anomalías en las mediciones.
    - Predecir valores futuros de sensores ambientales.
- 

### 4. Desarrollo por componentes

#### Hardware IoT (Arduino)

- Código en C++ usando librería **Adafruit DHT**.

- Lecturas de temperatura, humedad y luz cada 5 segundos.
- Envío de datos en formato **JSON** vía puerto serie.
- Ejemplo de salida:

JSON

```
{ "temperature": 25.3, "humidity": 43.7, "light": 320 }
```

## Backend (Flask API)

- API REST ligera con **Flask + pandas**.
- Carga datos desde Google Sheets (CSV export) o un archivo local.
- Ejemplo de consulta:

None

```
GET /data?sensor=temperature&device_id=esp32-1&start_date=2024-01-01
```

- Respuesta:

JSON

```
{  
  "records": 123,  
  "filters": {"sensor": "temperature", "device_id": "esp32-1", "start_date": "2024-01-01"},  
  "data": [  
  
    {"timestamp": "2024-01-02T12:00:00Z", "deviceId": "esp32-1", "value": 23.4, "unit": "°C", "sensor": "temperature", "type": "numeric"}  
  ]  
}
```

## Frontend (Flutter)

- Proyecto en **Flutter/Dart**.
- Módulos principales:
  - `lib/models/` → estructuras de datos de sensores.
  - `lib/services/` → cliente API para conectarse al backend.
  - `lib/presentation/` → pantallas y gráficos.
- **Funciones clave:**
  - Mostrar lista de sensores y dispositivos.
  - Gráficas interactivas de series temporales.
  - Adaptación multiplataforma (Android, iOS, Web).

## Inteligencia Artificial (Python ML)

- **Preprocesamiento de datos:** limpieza, conversión de fechas, encoding categórico.
  - **Detección de anomalías:** Isolation Forest con ~5–10% de outliers.
  - **Predicción:**
    - *Random Forest*: buena precisión en variables no lineales.
    - *Regresión Lineal*: base de comparación.
    - *LSTM*: aprendizaje profundo para series temporales.
  - **Predicciones futuras:** hasta 24 horas, generando series simuladas.
  - **Visualización:** gráficos automáticos exportados en PNG.
- 

## 5. Resultados

- Se implementó un **sistema IoT funcional** que recolecta datos ambientales.

- El **Backend API** permite filtrar y consultar datos históricos en JSON.
  - El **Frontend Flutter** brinda una interfaz amigable de acceso a la información.
  - El **modelo de ML** detectó anomalías y generó predicciones confiables de temperatura, humedad y CO<sub>2</sub>.
  - Visualizaciones gráficas facilitaron la interpretación de resultados.
- 

## 6. Conclusiones

- El proyecto integró **hardware, software, móvil y ML** en un sistema unificado.
  - La arquitectura es **escalable y modular**, lo que permite añadir sensores o expandir la API fácilmente.
  - El uso de **Machine Learning** aporta valor real al sistema, al detectar condiciones anómalas y anticipar tendencias.
  - La app móvil (Flutter) demostró la importancia de la visualización y accesibilidad multiplataforma.
  - EcoMonitor es una base sólida para aplicaciones **ambientales, agrícolas, industriales y educativas**.
- 

## 7. Posibles mejoras

- Integrar almacenamiento en **bases de datos en la nube** (PostgreSQL, Firebase, InfluxDB).
- Desplegar la API en un servidor productivo (AWS, GCP, Heroku).
- Mejorar el modelo de predicción usando **Redes Neuronales Avanzadas** (Transformers para series temporales).
- Implementar un **dashboard web** adicional con Streamlit o Grafana.